

Carta de fechamento

DOC Intelligence — Trilha B (front-end) Leopoldo Couto · 1º de setembro de 2026 Repositório: <https://github.com/eng-leopoldocouto/DOC-Intelligence>

O que ficou de fora, e por quê

A busca do que já foi processado — o quinto comportamento do produto — está projetada, servida pelo mock e **sem tela**. A fatia que o enunciado nomeia vai "do envio até a correção de um campo"; busca é uma segunda fatia, não a continuação desta, e construí-la pela metade produziria exatamente o que o enunciado penaliza. Ficaram também de fora o upload retomável, a priorização da fila, a deduplicação perceptual e a trilha de auditoria de leitura. Cada uma está em `07-nao-feito.md` com custo estimado e o **gatilho** que a tornaria necessária, porque "não fiz" sem estimativa é opinião.

Duas ausências me incomodam mais que as outras. O **HEIC do iPhone** é recusado com uma mensagem que ensina a mudar o ajuste da câmera: é solução organizacional para problema técnico, funciona, e depende de treinamento — que se perde na rotatividade. E a **priorização da fila** ficou de fora porque depende de uma pergunta que não tive tempo hábil de enviar ao senhor: existe SLA de mesmo dia? Assumi que não, documentei a premissa, e ela é a primeira coisa a mudar se eu estiver errado.

O que quebra primeiro se o volume for multiplicado por dez

Não é a interface — é a fila de conferência, e nenhuma decisão de front-end resolve isso.

A 1.500 documentos por dia e 8.000 no pico, os gargalos técnicos que tratei seguem de pé: o polling continua sendo uma requisição para N documentos, a fila continua paginada por cursor, o upload continua limitado a três simultâneos. O que quebra é aritmética. Duas pessoas do atendimento, aos quatro minutos por documento que o enunciado cita, conferem cerca de 240 por dia. Com 8.000 chegando entre 9h e 11h e uma fração relevante caindo na conferência por baixa confiança, **a fila não drena — ela acumula indefinidamente**, e hoje nada na minha interface avisa o gestor de que isso está acontecendo.

Esse é o achado que eu levaria para a primeira reunião depois de entregar: o próximo investimento não é técnico, é elevar o limiar de confiança que dispensa conferência, ou aceitar amostragem em vez de conferência integral. Ambas são decisões do escritório, não do desenvolvedor — mas é o desenvolvedor que precisa mostrar a conta.

Qual das minhas decisões eu menos defenderia hoje

O PATCH que grava e **conclui** a conferência na mesma operação, sem permitir salvar rascunho.

Meu argumento foi legítimo: rascunho num documento reservado por TTL cria um estado que ninguém sabe interpretar quando a reserva expira, e preferi não ter a funcionalidade a ter uma que confunde. Mas o custo real cai sobre quem usa. A pessoa que está conferindo um contracheque com seis campos, é chamada no balcão e volta dez minutos depois, **perde tudo**. Otimizei para a limpeza do meu modelo de estados em vez de otimizar para o operador — e num sistema que existe para poupar quatro minutos por documento, fazer alguém repetir dez é o tipo de troca que eu não faria de novo.

A correção não é difícil: rascunho local que expira junto com a reserva, com aviso explícito de que não está salvo no servidor. Não a fiz por prazo, e é a primeira coisa que eu mudaria.

Quanto tempo isso tudo levou

3h20 de trabalho efetivo, somando a coluna de duração de `docs/ia/registro-de-tempo.md`. Começou às 19h17 de 31 de agosto de 2026 e terminou na madrugada do dia seguinte, com uma interrupção de cerca de duas horas por limite de uso da ferramenta, não contabilizada.

Devo uma ressalva sobre esse arquivo, e ela é a coisa mais útil que aprendi nesta entrega. Três linhas dele traziam horários **estimados para a frente** — o commit que as gravou é anterior ao horário que elas declaravam como início. O agente auditor apontou, comparando a tabela com o `git log`. Corrigi. **E reincidi na correção**: ao consertar duas linhas, escrevi na terceira um término dezoito minutos à frente do commit que a gravava, dentro do parágrafo que acabara de explicar por que isso é inaceitável. A segunda auditoria pegou.

O conserto definitivo não foi um número melhor: foi tirar do arquivo a possibilidade de errar. A coluna "fim" da fase em andamento passou a dizer *"ver último commit"* — não se data prospectivamente um campo que aponta para o histórico.

E caí uma terceira vez, no mesmo arquivo: ao consertar a fase 8, mudei dois valores da coluna e repeti o total antigo no mesmo diff. A terceira auditoria pegou, e nomeou o padrão que eu não estava vendo: o

defeito não está no item apontado — está no vizinho aritmético dele, ou no outro documento que o cita. Daí a regra que passei a seguir e que devia ter seguido desde o início: **procurar pelo número, não pelo assunto**. grep do número acha em quinze segundos o que reler o parágrafo não achou três vezes.

Registre as três correções em vez de apagar os erros. Um documento que se apresenta como relógio real não pode conter estimativa disfarçada — e as quedas sucessivas dizem mais sobre como eu trabalho do que a versão limpa diria.

A distribuição diz mais que o total: **por volta de 40% do tempo foi spec, ADRs e registro de decisão, antes de existir uma linha de código**. A especificação inteira e as treze ADRs saíram em vinte e dois minutos de escrita; o plano de implementação, em dezoito. Foi o melhor investimento da entrega — a fatia vertical foi construída sem uma única decisão de arquitetura tomada no meio do código, e as **nove** divergências que apareceram estão registradas contra uma spec que ficou congelada numa tag desde antes do primeiro commit de implementação. Quatro delas só existem porque um subagente auditor, rodando em contexto frio, encontrou o que eu não tinha encontrado no meu próprio texto.

Trabalhei com o Claude Opus 5 em sessão interativa. O prazo foi comprimido de três dias para menos de um por decisão minha, o que tornou o recorte mais importante que a execução — e é por isso que a maior parte do que entrego é texto, e não código.

Se houver uma única coisa a levar desta entrega sobre trabalhar com agentes, é esta: **o autor não consegue auditar o próprio texto contra o próprio código**, porque lê o texto e lembra da intenção em vez de ver o que ficou. O valor do subagente auditor não foi capacidade técnica — foi não ter memória do que eu quis dizer. Rodei-o **três vezes**, e as três encontraram algo: a segunda achou o que a primeira correção tinha introduzido, e a terceira, o que a segunda introduziu. O agente não erra por incompetência; erra por escopo de atenção — corrige com precisão o que foi apontado e não olha ao lado. **Eu também não. A diferença é que eu achava que estava olhando.**