

Carta de fechamento

DOC Intelligence — Trilha B (front-end) Leopoldo Couto · 31 de agosto de 2026 Repositório: <https://github.com/eng-leopoldocouto/DOC-Intelligence>

O que ficou de fora, e por quê

A busca do que já foi processado — o quinto comportamento do produto — está projetada, servida pelo mock e **sem tela**. A fatia que o enunciado nomeia vai "do envio até a correção de um campo"; busca é uma segunda fatia, não a continuação desta, e construí-la pela metade produziria exatamente o que o enunciado penaliza. Ficaram também de fora o upload retomável, a priorização da fila, a deduplicação perceptual e a trilha de auditoria de leitura. Cada uma está em 07-nao-feito.md com custo estimado e o **gatilho** que a tornaria necessária, porque "não fiz" sem estimativa é opinião.

Duas ausências me incomodam mais que as outras. O **HEIC do iPhone** é recusado com uma mensagem que ensina a mudar o ajuste da câmera: é solução organizacional para problema técnico, funciona, e depende de treinamento — que se perde na rotatividade. E a **priorização da fila** ficou de fora porque depende de uma pergunta que não tive tempo hábil de enviar ao senhor: existe SLA de mesmo dia? Assumi que não, documentei a premissa, e ela é a primeira coisa a mudar se eu estiver errado.

O que quebra primeiro se o volume for multiplicado por dez

Não é a interface — é a fila de conferência, e nenhuma decisão de front-end resolve isso.

A 1.500 documentos por dia e 8.000 no pico, os gargalos técnicos que tratei seguem de pé: o polling continua sendo uma requisição para N documentos, a lista continua virtualizada, o upload continua limitado a três simultâneos. O que quebra é aritmética. Duas pessoas do atendimento, aos quatro minutos por documento que o enunciado cita, conferem cerca de 240 por dia. Com 8.000 chegando entre 9h e 11h e uma fração relevante caindo na conferência por baixa confiança, **a fila não drena — ela acumula indefinidamente**, e hoje nada na minha interface avisa o gestor de que isso está acontecendo.

Esse é o achado que eu levaria para a primeira reunião depois de entregar: o próximo investimento não é técnico, é elevar o limiar de confiança que dispensa conferência, ou aceitar amostragem em vez de conferência integral. Ambas são decisões do escritório, não do desenvolvedor — mas é o desenvolvedor que precisa mostrar a conta.

Qual das minhas decisões eu menos defenderia hoje

O PATCH que grava e **conclui** a conferência na mesma operação, sem permitir salvar rascunho.

Meu argumento foi legítimo: rascunho num documento reservado por TTL cria um estado que ninguém sabe interpretar quando a reserva expira, e preferi não ter a funcionalidade a ter uma que confunde. Mas o custo real cai sobre quem usa. A pessoa que está conferindo um contracheque com seis campos, é chamada no balcão e volta dez minutos depois, **perde tudo**. Otimizei para a limpeza do meu modelo de estados em vez de otimizar para o operador — e num sistema que existe para poupar quatro minutos por documento, fazer alguém repetir dez é o tipo de troca que eu não faria de novo.

A correção não é difícil: rascunho local que expira junto com a reserva, com aviso explícito de que não está salvo no servidor. Não a fiz por prazo, e é a primeira coisa que eu mudaria.

Quanto tempo isso tudo levou

Cerca de três horas de trabalho efetivo, começando às 19h17 de 31 de agosto de 2026 e terminando às 00h45 do dia seguinte, com uma interrupção de duas horas por limite de uso da ferramenta. O tempo está carimbado por fase em docs/ia/registro-de-tempo.md.

Devo uma ressalva sobre esse arquivo, porque ela é do mesmo tipo que a entrega inteira se propõe a não ter. Três linhas dele traziam horários **estimados para a frente** — o commit que as gravou é anterior ao horário que elas declaravam como início. Foi o agente auditor que apontou, comparando

a tabela com o `git log`. Corrigi para os horários reais e **registre a correção em vez de apagar o erro**: um documento que se apresenta como relógio real não pode conter estimativa disfarçada, ainda mais sendo esta a resposta que se apoia nele.

A distribuição diz mais que o total: **por volta de 40% do tempo foi spec, ADRs e registro de decisão, antes de existir uma linha de código**. A especificação inteira e as treze ADRs saíram em vinte e dois minutos de escrita; o plano de implementação, em vinte e um. Foi o melhor investimento da entrega — a fatia vertical foi construída sem uma única decisão de arquitetura tomada no meio do código, e as cinco divergências que apareceram estão registradas contra uma spec que ficou congelada numa tag desde antes do primeiro commit de implementação.

Trabalhei com o Claude Opus 5 em sessão interativa. O prazo foi comprimido de três dias para menos de um por decisão minha, o que tornou o recorte mais importante que a execução — e é por isso que a maior parte do que entrego é texto, e não código.